

ChangeCheck

改版验收官

发现新增错误 把修复验到底

改提示词、换模型之后，用同一测试集比较两版，定位新增错误，再验证修复结果。

36

内置样例

3 次

推荐重复

40

通过测试

MIT

开源协议

队名：分子 | 邱全安 · 童梓荣 · 王清松

github.com/nghqqa/changecheck

总分提高，也要检查新增风险

同一测试集 / 两个版本 / 每条重复 3 次

基线样例通过

27 / 36

候选样例通过

36 / 36

新增关键违规

11

mock 模拟实跑：多数通过不能掩盖偶发关键错误

01 / 项目背景与应用场景

让开发者看清改版带来的变化

一个看似“更完整”的答案，可能是新错误

通知原文

请于10月12日提交实验报告，具体提交时间另行通知。

旧版：保留未知

time = ""

新版：凭空补全

time = "18:00"

目标用户

个人开发者与小团队：经常改提示词、切换模型，但缺少稳定的改版验收流程。

要回答的三个问题

哪些原本正确的输入被改坏？

哪些关键要求出现了新违规？

改善是否值得额外费用与耗时？

通知信息提取

已经提供完整示例

保留原文日期、缺失留空、改期取最终安排。适合校园通知和活动信息整理。

客服工单结构化

可用自定义字段接入

提取主题、优先级与截止时间；对照人工参考答案，检查新增漏提取或补全。

订单与业务字段

可迁移的同类场景

定义扁平字符串字段，用固定的参考答案和关键约束验收模型或提示词变更。

当前适用范围：有参考答案的“文本输入 → 扁平 JSON 字符串字段输出”；验收依据由开发者确认。

02 / 产品形态与使用流程

四步建立可以重复执行的验收

01 确认标准

业务要求 → 检查项



02 维护测试集

输入 + 参考答案



03 配置两版

提示词 / 模型 / 参数



04 对比与复跑

错误证据 → 修复验证

你的原始描述：「从通知里提取日期、时间和地点；没写的信息必须留空，绝对不能编造；改期了取最终安排，日期和时间保持原文，不做换算。只输出 JSON。」 | 确认时间：2026/10/9 14:30:46

- ✓ R01 原文未提及的字段必须留空（凭空补全 = 关键违规）
- ✓ R02 严禁编造：宁可留空，不可补默认值/估计值
- ✓ R03 多次变更取最终安排，已作废的日期/地点视为干扰信息
- ✓ R04 值与通知原文逐字一致：不改写、不换算（如下午2:00 ≠ 14:00；关闭后近似差异仅进入人工复核）
- ✓ R05 勾选零容忍字段：这些字段的失败将单独标为「违反关键要求」
- ✓ R06 输出为合法 JSON，且仅含任务约定的字段
- ✓ R07 主体字段（第一个字段）识别出正确名称（命名等价即可；关闭则要求逐字一致）

检查器当前生效规则：☒ 逐字一致 开 ☒ 事项名等价 开 ☒ 补全零容忍 开

这些开关由你的确认项派生，检查时真实读取——取消勾选某条要求，检查行为会随之改变。

实际界面：检查项经人工确认后固化，规则开关随确认项生效。

规则引导采用确定性解析；参考答案与关键字段由开发者维护。测试资产可导出为 JSON，线上发现的错误也能持续回流为回归用例。

03 / 核心能力与修复闭环

报告先把新增错误交到你手上

样例通过数

27/36 → 36/36

新增关键违规

11 条

验收建议

修复后复跑

本次 mock 实跑 / 36 条 × 2 版 × 3 次 = 216 条调用记录

● 关键违规被多数决掩盖

缺失

#83 经典案例：具体时间另行通知，补出任何钟点（如18:00）即为凭空捏造

通知原文：请于10月12日提交实验报告，具体提交时间另行通知。

参考答案：{"event": "实验报告提交", "date": "10月12日", "time": "", "location": "", "deadline": ""}

基线输出：{"event": "实验报告提交", "date": "10月12日", "time": "", "location": "", "deadline": ""}

候选输出：{"event": "实验报告提交", "date": "10月12日", "time": "18:00", "location": "", "deadline": ""}

字段	违反规则	期望	实际	关键
time	empty(必须留空)	""	18:00	●

证据直接指向 time：期望留空，候选却输出 18:00。

开发者修改 → 选择修复版 → 同一基线复跑

新增关键违规 11 → 0

运行 #5 / #6 为最新版本本地模拟验证；用于演示验收逻辑，不代表真实模型性能。

04 / 场景验证与效果证据

真实模型实验：精简提示词也会退步

历史真实 API 归档 / deepseek-flash / 36 条样例 / 每版每条重复 3 次 / 2026.10.07

版本	样例通过	费用估算	平均耗时
基线 · 稳定提示词	34 / 36	¥0.2005	1232 ms
候选 · 精简提示词	28 / 36	¥0.3468	2230 ms

8

新增失败

2

新增通过

两版比较同时呈现退步与改善，避免只凭候选总分判断改版。

真实案例：唯一时间点被搬进了 deadline

原文：请各部门在10月30日前完成年度总结并提交至OA系统。

字段	违反规则	期望	实际	关键
event	exact(事项名等价)	年度总结提交	年度总结	
date	required(必须提取)	10月30日	""	
deadline	empty(必须留空)	""	10月30日前	●

来源：仓库 fixtures/demo-runs.json（盲测归档）及 docs/evidence/web-runs/run-2.md。历史结果按原始判定口径解读，本次未重新调用付费模型；费用按实验时配置单价估算。

05 / 技术架构与创新点

一套内核，支撑网页与开发流程



以新增退步为核心

逐条比较旧版与新版，优先展示本次改版引入的错误。

关键风险不被平均值掩盖

按字段独立比较关键违规；偶发坏输出单独参与复核。

证据支持修复与复跑

同时展示原文、参考答案、两版输出与违反规则；保留运行快照。

可接入现有开发流程

Web 与 CLI 共用内核，CI 通过退出码表达放行、阻断或复核。

运行技术栈：Next.js 15 / React 19 / TypeScript / Node.js / SQLite。最终采用决定保留人工确认。

可运行、可复现、可持续维护

快速体验

Docker 启动

docker compose up -d

打开 localhost:3000，选择 mock 模式即可体验。

本地开发

npm install / npm run dev

真实模型模式需配置接口密钥；仓库提供 CLI 示例、测试命令和部署文件。

已经交付的开源基础

MIT 协议

明确许可；保留源码与依赖清单。

贡献与问题反馈

提供贡献指南、Bug 与功能建议模板。

自动验证

40 项测试通过，最新版本生产构建通过。

可复核材料

保存样例、版本、历史实验及报告导出。

后续计划

近期

补充工单、订单模板，收集真实试用反馈。

下一阶段

完善严格名称匹配、人工复核与规则配置。

后续评估

扩展更多输出结构，探索 MCP 等接入方式。

项目与复核入口

代码仓库: github.com/nghqqa/changecheck

赛事要求: www.oschina.net/os2026/

真实实验: [docs/evidence/web-runs/run-2.md](https://docs.evidence/web-runs/run-2.md)

分子团队: 邱全安 · 童梓荣 · 王清松